

Ian Cumes | Carne 23236

<https://github.com/iancumes/Lab1DeepLearning>

CAPAS Y ACTIVACIONES

Componente	Proposito y parametros
nn.Linear	Transformacion afin $y=x \cdot T + b$. in_features , out_features y bias controlan dimensiones y termino independiente.
nn.ReLU	$\max(0, x)$: simple y eficiente; puede dejar neuronas inactivas si sus entradas permanecen negativas.
nn.LeakyReLU	Mantiene pendiente negative_slope =0.01 en $x < 0$ y conserva flujo de gradiente.
nn.Tanh	Salida centrada en $[-1, 1]$; puede saturarse para magnitudes altas y reducir el gradiente.
nn.Dropout	Anula activaciones con probabilidad p durante train; se desactiva en evaluacion y reduce coadaptacion.
nn.BatchNorm1d	Normaliza cada feature del minibatch. num_features , eps y momentum controlan forma y estadisticas moviles.

PERDIDAS Y OPTIMIZADORES

Elemento	Funcion y diferencia
MSELoss	Promedia errores cuadrados; enfatiza errores grandes. Objetivo principal.
L1Loss	Promedia errores absolutos; mas robusta ante extremos, no suave en cero.
SmoothL1Loss	Cuadratica cerca de cero y lineal lejos; beta fija la transicion.
SGD	Paso opuesto al gradiente; momentum suaviza oscilaciones. Exige ajustar lr .
Adam	Momentos adaptativos por parametro (betas , eps); convergencia inicial rapida.
RMSprop	Escala por media movil del gradiente cuadrado; alpha controla memoria.

lr: tamano del paso; alto puede oscilar y bajo converge lentamente. **weight_decay**: penalizacion L2 aplicada por el optimizador. **L1**: se suma explicitamente como lambda por la suma de valores absolutos.

DATOS, PREPARACION Y CONTROL DE FUGA

Dataset: 20,640 distritos, 8 features numericas y target MedHouseVal en USD 100,000. No hay nulos, duplicados ni variables categoricas. La regla IQR detecta extremos que se conservan por ser plausibles. El techo 5.00001 contiene 965 observaciones y limita la informacion sobre viviendas de mayor precio.

Split: 70/15/15 = 14,448 train, 3,096 validacion y 3,096 test. StandardScaler se ajusta solo con train. Validacion decide hiperparametros; test se consulta una vez despues de cerrar la seleccion.

MLP: Linear - BatchNorm opcional - activacion - Dropout opcional; salida Linear(1) sin activacion. CPU, semilla 42, algoritmos deterministas y checkpoint de menor RMSE de validacion.

Fuentes: scikit-learn California Housing; documentacion oficial de torch.nn y torch.optim.


BUSQUEDA CONTROLADA DE HIPERPARAMETROS

17 corridas | metricas exclusivamente de validacion

Baseline: [64,32] | ReLU | Adam lr=0.001 | batch=64 | 100 epochs | MSE | sin regularizacion

E	Variacion	Arq./Act.	Opt./LR	B/E	Regularizacion	Best	MSE	MAE	RMSE	s
1	Baseline	64-32 ReLU	Adam 0.001	64 100	-	99	0.2870	0.3661	0.5357	30.2
2	Arquitectura pequena	32 ReLU	Adam 0.001	64 100	-	99	0.3175	0.3852	0.5635	22.6
3	Arquitectura profunda	128-64-32 ReLU	Adam 0.001	64 100	-	64	0.2853	0.3596	0.5341	36.1
4	Activacion LeakyReLU	64-32 LeakyReLU	Adam 0.001	64 100	-	94	0.2866	0.3640	0.5354	30.7
5	Activacion Tanh	64-32 Tanh	Adam 0.001	64 100	-	94	0.2851	0.3620	0.5340	46.9
6	Optimizador SGD	64-32 ReLU	SGD 0.01	64 100	-	99	0.2795	0.3584	0.5286	29.6
7	Optimizador RMSprop	64-32 ReLU	RMSprop 0.001	64 100	-	94	0.2853	0.3605	0.5341	31.2
8	Learning rate alto	64-32 ReLU	Adam 0.01	64 100	-	61	0.2789	0.3575	0.5282	30.0
9	Learning rate bajo	64-32 ReLU	Adam 0.0001	64 100	-	99	0.3386	0.4000	0.5819	31.0
10	Batch pequeno	64-32 ReLU	Adam 0.001	32 100	-	64	0.2814	0.3576	0.5304	39.0
11	Batch grande	64-32 ReLU	Adam 0.001	256 100	-	90	0.2975	0.3740	0.5454	15.4
12	Menos epochs	64-32 ReLU	Adam 0.001	64 50	-	40	0.2999	0.3729	0.5476	14.7
13	Mas epochs	64-32 ReLU	Adam 0.001	64 150	-	109	0.2847	0.3619	0.5335	44.4
14	Regularizacion L1	64-32 ReLU	Adam 0.001	64 100	L1=1e-05	94	0.2859	0.3600	0.5347	36.7
15	Regularizacion L2	64-32 ReLU	Adam 0.001	64 100	L2=0.0001	94	0.2855	0.3620	0.5343	33.3
16	Dropout	64-32 ReLU	Adam 0.001	64 100	Dropout=0.2	99	0.2971	0.3711	0.5450	33.4
17	Batch normalization	64-32 ReLU	Adam 0.001	64 100	BatchNorm	97	0.2849	0.3605	0.5337	38.6

Curvas de perdida seleccionadas



LECTURA DE RESULTADOS

Ganador: E8 (Learning rate alto), RMSE=0.5282; mejora 0.0075 frente al baseline. El lr=0.01 avanza mas por actualización sin divergir.

Mayor impacto negativo: E9 (Learning rate bajo), RMSE=0.5819. El lr=0.0001 fue demasiado conservador para 100 epochs y produjo underfitting relativo.

Regularizacion: L1=0.5347, L2=0.5343, Dropout=0.5450. L2 fue la mejor de estas tres, aunque la mejora frente al baseline fue pequeña; Dropout perjudico este MLP compacto.

Velocidad: batch 256 fue mas rapido, pero menos preciso; batch 32 requirio mas actualizaciones. 150 epochs mejoro respecto a 50, aunque el checkpoint optimo aparecio antes del final.

MODELO FINAL, DISCUSION Y CONCLUSIONES

Seleccion cerrada con validacion; evaluacion de test realizada una sola vez

CONFIGURACION GANADORA E8 lr=0.01 [64,32] - ReLU - Adam - batch 64	TEST MSE 0.2516 unidades del target al cuadrado	TEST MAE 0.3481 aprox. USD 34,814	TEST RMSE 0.5016 aprox. USD 50,156
---	--	--	---

DISCUSION 1-3

- 1. Impacto.** El cambio positivo mayor fue elevar lr de 0.001 a 0.01: RMSE bajo de 0.5357 a 0.5282. El peor cambio fue lr=0.0001 (RMSE 0.5819), porque avanza muy poco en 100 epochs.
- 2. Overfitting/underfitting.** Las curvas y la brecha val-train identifican sobreajuste cuando train sigue bajando pero validacion deja de mejorar. El checkpoint por mejor epoch evita conservar una etapa posterior peor. El lr bajo mostro underfitting relativo por convergencia insuficiente.
- 3. Regularizacion.** L2 fue la mejor entre L1/L2/Dropout (RMSE 0.5343), pero la ganancia fue marginal. Dropout elimino capacidad util en una red pequena y elevo el error.

DISCUSION 4-6

- 4. Batch y epochs.** Batch 256 tardo 15.4s frente a 39.0s con batch 32, pero tuvo peor RMSE. Mas epochs ofrecen oportunidad de converger, no garantia de generalizar; el mejor checkpoint puede ocurrir antes.
- 5. Metricas.** MSE enfatiza errores grandes y queda en unidades cuadradas; MAE expresa el error absoluto tipico y resiste mejor outliers; RMSE conserva la penalizacion cuadratica en las unidades originales.
- 6. Produccion.** Se elegiria E8 como punto de partida y busqueda bayesiana con validacion cruzada. Tambien se monitorearian drift, error por region y segmento, latencia y el efecto del target censurado antes del despliegue.

LIMITACIONES, CONCLUSION Y REFERENCIAS

Limitaciones. El techo del target impide conocer el precio real de 965 distritos; un split aleatorio puede colocar zonas cercanas en conjuntos distintos y ser optimista respecto a generalizacion geografica. Una sola semilla no cuantifica variabilidad. El modelo aprende asociaciones, no causalidad.

Conclusion. El MLP final generalizo con RMSE de USD 50,156 y MAE de USD 34,814. La tasa de aprendizaje tuvo el mayor efecto: un paso mayor mejoro convergencia, mientras uno bajo dejo el modelo corto de entrenamiento. Regularizacion y complejidad deben decidirse con validacion, no por intuicion ni observando test.

Referencias: scikit-learn, California Housing dataset; PyTorch, torch.nn API y torch.optim API. https://scikit-learn.org/stable/modules/generated/sklearn.datasets.fetch_california_housing.html | <https://docs.pytorch.org/docs/stable/nn.html> | <https://docs.pytorch.org/docs/stable/optim.html>