

Laboratorio 1: Entrenamiento de Redes Neuronales

MLP de regresion aplicado a California Housing

Curso: CC3092 - Deep Learning y Sistemas Inteligentes

Estudiante: Ian Cumes

Carne: 23236

Repositorio: <https://github.com/iancumes/Lab1DeepLearning>

1. Dataset y preparacion

California Housing contiene 20,640 observaciones, ocho variables predictoras numericas y el objetivo MedHouseVal en unidades de USD 100,000. No se encontraron nulos, duplicados ni variables categoricas. Los valores atipicos detectados con IQR se conservaron por representar distritos plausibles; 965 observaciones alcanzan el techo 5.00001 del target.

2. Capas, activaciones y funciones de perdida

Componente	Funcion	Parametros mas relevantes
nn.Linear	Transformacion afin entre capas.	in_features, out_features, bias
nn.ReLU	Activa con $\max(0, x)$; simple y eficiente.	inplace
nn.LeakyReLU	Conserva gradiente para entradas negativas.	negative_slope, inplace
nn.Tanh	Comprime activaciones al intervalo $[-1, 1]$.	Sin parametros entrenables
nn.Dropout	Anula activaciones aleatoriamente solo en train.	p, inplace
nn.BatchNorm1d	Normaliza features del minibatch y mantiene estadisticas.	num_features, eps, momentum, affine
nn.MSELoss	Error cuadratico; penaliza fuertemente errores grandes.	reduction
nn.L1Loss	Error absoluto; mayor robustez ante valores extremos.	reduction
nn.SmoothL1Loss	Transicion entre error cuadratico y absoluto.	beta, reduction

3. Optimizadores y metodologia

Optimizador	Funcion y diferencia	Parametros
SGD	Actualiza contra el gradiente; momentum suaviza oscilaciones.	lr, momentum, weight_decay
Adam	Usa momentos adaptativos por parametro; converge rapidamente.	lr, betas, eps, weight_decay
RMSprop	Escala por una media movil del gradiente cuadrado.	lr, alpha, momentum, weight_decay


El learning rate (lr) controla el tamano del paso: un valor alto puede oscilar y uno bajo puede converger lentamente. weight_decay agrega regularizacion L2. Para prevenir fuga, se uso un split 70/15/15 (14,448/3,096/3,096), StandardScaler ajustado solo con train y test aislado hasta cerrar la seleccion. El MLP configurable usa bloques Linear - BatchNorm opcional - activacion - Dropout opcional y una salida lineal escalar.

4. Resultados de las 17 iteraciones

Todas las metricas de la tabla corresponden a validacion. Se selecciono por menor RMSE, con MAE, numero de parametros y tiempo como desempates. La fila resaltada es la configuracion ganadora.

E	Variacion	Configuracion principal	Best	MSE	MAE	RMSE
1	Baseline	[64-32] ReLU; Adam lr=0.001; B64/E100; sin reg.	99	0.2870	0.3661	0.5357
2	Arquitectura pequena	[32] ReLU; Adam lr=0.001; B64/E100; sin reg.	99	0.3175	0.3852	0.5635
3	Arquitectura profunda	[128-64-32] ReLU; Adam lr=0.001; B64/E100; sin reg.	64	0.2853	0.3596	0.5341
4	Activacion LeakyReLU	[64-32] LeakyReLU; Adam lr=0.001; B64/E100; sin reg.	94	0.2866	0.3640	0.5354
5	Activacion Tanh	[64-32] Tanh; Adam lr=0.001; B64/E100; sin reg.	94	0.2851	0.3620	0.5340
6	Optimizador SGD	[64-32] ReLU; SGD lr=0.01; B64/E100; sin reg.	99	0.2795	0.3584	0.5286
7	Optimizador RMSprop	[64-32] ReLU; RMSprop lr=0.001; B64/E100; sin reg.	94	0.2853	0.3605	0.5341
8	Learning rate alto	[64-32] ReLU; Adam lr=0.01; B64/E100; sin reg.	61	0.2789	0.3575	0.5282
9	Learning rate bajo	[64-32] ReLU; Adam lr=0.0001; B64/E100; sin reg.	99	0.3386	0.4000	0.5819
10	Batch pequeno	[64-32] ReLU; Adam lr=0.001; B32/E100; sin reg.	64	0.2814	0.3576	0.5304
11	Batch grande	[64-32] ReLU; Adam lr=0.001; B256/E100; sin reg.	90	0.2975	0.3740	0.5454
12	Menos epochs	[64-32] ReLU; Adam lr=0.001; B64/E50; sin reg.	40	0.2999	0.3729	0.5476
13	Mas epochs	[64-32] ReLU; Adam lr=0.001; B64/E150; sin reg.	109	0.2847	0.3619	0.5335
14	Regularizacion L1	[64-32] ReLU; Adam lr=0.001; B64/E100; L1=1e-05	94	0.2859	0.3600	0.5347
15	Regularizacion L2	[64-32] ReLU; Adam lr=0.001; B64/E100; L2=0.0001	94	0.2855	0.3620	0.5343
16	Dropout	[64-32] ReLU; Adam lr=0.001; B64/E100; Dropout=0.2	99	0.2971	0.3711	0.5450
17	Batch normalization	[64-32] ReLU; Adam lr=0.001; B64/E100; BatchNorm	97	0.2849	0.3605	0.5337

Figura 1. Curvas de perdida de baseline, mejor, peor y mayor brecha de generalizacion



Resultado clave: E8 ([64,32], ReLU, Adam, lr=0.01, batch 64) alcanza RMSE de validacion 0.5282 en el epoch 61. El learning rate alto mejoro 0.0075 RMSE frente al baseline; lr=0.0001 fue el cambio mas negativo (RMSE 0.5819).

5. Discusion y analisis

Impacto de hiperparametros. El mayor impacto positivo fue elevar lr de 0.001 a 0.01: RMSE bajo de 0.5357 a 0.5282. El mayor impacto negativo fue reducirlo a 0.0001 (0.5819), porque 100 epochs no bastaron para avanzar con pasos tan pequenos.

Overfitting y underfitting. Las curvas identifican sobreajuste cuando train continua bajando y validacion deja de mejorar. Conservar el checkpoint de menor RMSE evita usar un estado posterior peor. E9 mostro underfitting relativo por convergencia insuficiente, no por falta de neuronas.

Regularizacion. Entre L1, L2 y Dropout, L2 fue la mejor (RMSE 0.5343), aunque la mejora frente al baseline fue pequena. Dropout empeoro a 0.5450 porque redujo capacidad util en una red compacta sin sobreajuste severo.

Batch size y epochs. Batch 256 fue mas rapido (15.4 s) pero menos preciso (0.5454); batch 32 tomo 39.0 s y obtuvo 0.5304. Pasar de 50 a 150 epochs mejoro 0.0141 RMSE, pero el mejor checkpoint de la corrida larga aparecio en epoch 109, no al final.

MSE, MAE y RMSE. MSE enfatiza errores grandes y queda en unidades cuadradas; MAE representa el error absoluto promedio y resiste mejor outliers; RMSE mantiene la penalizacion cuadratica en las unidades originales. En test: MSE 0.2516, MAE 0.3481 y RMSE 0.5016.

Eleccion para produccion. Se elegiria E8 como punto de partida y una busqueda bayesiana con validacion cruzada sobre lr , arquitectura, weight decay y batch size. Tambien se evaluarian splits geograficos, varias semillas, drift, latencia y el efecto del target censurado.

6. Evaluacion final y conclusiones

Tras cerrar la seleccion, E8 se reentreno con train+validacion durante 61 epochs y se evaluo test una sola vez. El MAE fue aproximadamente USD 34,814 y el RMSE USD 50,156. La tasa de aprendizaje tuvo el mayor efecto observado; arquitectura y regularizacion solo produjeron cambios modestos. El resultado debe interpretarse considerando el techo del target, el split aleatorio y el uso de una sola semilla.